OpenVLA K → G → A 가설 검증 결과 보고서 (실사 이미지)

프로젝트: 예픽 — Tracing World Knowledge into Embodied Action in VLA Models
모델: OpenVLA-7B (`gen-robot/openvla-7b-rlvla-sft_16k`) · **환경:** SimplerEnv / ManiSkill (Act2Answer 프로토콜)
작성일: 2026-10-05 · **본 실험:** 실제 사진 타일 3개 세트, 360 에피소드 (오류 0) · **팀원 실험:** 5개 카테고리(public_info, time_clock, celebrity, living_world, traffic) 3,060 에피소드

요약

- **행동 결과는 모든 세트에서 같다.** 본 실험(State, Attribute, Emotion)과 팀원 실험 5개 카테고리(public_info, time_clock, celebrity, living_world, traffic) 모두에서 로봇은 지식 질문(Semantic reasoning)과 정답 이름 제시(Explicit object)에서 **우연 수준(약 41~55%)**이고, "왼쪽/오른쪽 타일" 지시(Explicit spatial)에서만 **87~100%** 성공한다.
- **실패는 동작 제어 문제가 아니며, 정답 이름을 알려줘도 해결되지 않는다.** 로봇은 지시 내용보다 **위치(한쪽 타일)**에 따라 고른다. 팀원 데이터에서도 성공률이 정답 위치에 따라 크게 갈린다 (예: public_info 지식 질문 13% ↔ 73%, celebrity 정답 이름 제시 74% ↔ 19%).
- **내부 표현(probe):** 실제 사진에서는 정답(K)이 OpenVLA의 hidden state에서 읽히지 않는다 (State·Attribute는 chance 이하, Emotion은 70~75%지만 chance와 유의한 차이 없음). 따라서 "K는 표현에 있지만 G로 가며 손실된다"는 **가설은 실사 이미지에서 지지되지 않았다.**

표 1. 판정 요약 (본 실험)

테스트	문제 수	사전 등록 판정	Robustness check 판정	지식 질문 intent	위치 제시 intent
State (사진)	30	NO-GO	NO-GO	50% (30/60)	80% (48/60)
Attribute (사진)	20	INCONCLUSIVE (위치 제시 intent 75% < 80%)	INCONCLUSIVE (위치 제시 intent 75% < 80%)	55% (22/40)	75% (30/40)
Emotion (사진)	10	GO	NO-GO	45% (9/20)	80% (16/20)

1. 무엇을 검증했나

연구제안서의 핵심 가설:

> VLA 내부에 올바른 world-knowledge answer(**K**)가 recoverable하더라도, 이를 visual scene의 physical target(**G**)으로 grounding하는 과정에서 정보가 손실된다. (K → G → A)

과제는 Act2Answer와 같다. 탁자 위에 사진 타일 두 장이 있고, 로봇은 지시문을 읽고 정답 타일 위에 큐브를 올려놓는다. 각 문제는 좌우 배치를 바꾼 버전(noswap / swap)으로 두 번 실행된다.



그림 1. 실제 실행 장면 (시작 · 중간 · 끝). 지시문: "Place the cube on the answer to this question: Which door could a person walk straight through without touching it?" → 로봇이 열린 문(왼쪽) 위에 큐브를 놓음 (성공).

2. 실험 설계

2.1 같은 장면, 세 가지 지시문 (matched control)

장면, 타일, 정답 위치, 로봇 초기 상태, seed는 모두 같고 **지시문만** 바꾼다.

조건	지시문 예시	필요한 변환	역할
지식 질문 (Semantic reasoning)	Place the cube on the answer to this question: Which door keeps the room private?	지식 → 물체 → 위치 → 행동	본 과제
정답 이름 제시 (Explicit object)	Place the cube on the tile showing the closed door.	물체 → 위치 → 행동	지식 단계 제거
위치 제시 (Explicit spatial)	Place the cube on the left tile.	위치 → 행동	motor floor



그림 2. 같은 장면에 "Place the cube on the left tile." 지시 (Explicit spatial).

2.2 측정 지표

지표	의미	chance
Placement success	큐브가 정답 타일 위에 놓였는가	50%
Intent (팔이 정답 타일로 갔는가)	실제 팔 이동 궤적이 정답 타일을 향했는가	50%
양쪽 배치 모두 정답	noswap과 swap 둘 다 맞혀야 1문제 정답. 한쪽만 고르는 로봇은 0%	25%
왼쪽 선택 비율	50%에서 멀수록 내용이 아니라 위치로 고르고 있음	50% (편향 없음)
K probe	hidden state에서 "두 타일 중 어느 것이 정답인지"를 선형 분류기로 읽을 수 있는가	50%
G probe	hidden state에서 "정답이 왼쪽인지 오른쪽인지"를 읽을 수 있는가	50%

Probe는 OpenVLA LLM의 마지막 prompt 토큰 hidden state(첫 추론 시점, 깊이 25/50/75/100%)에 학습하며, **처음 보는 질문 표현**으로만 평가한다 (5-fold, noswap/swap은 같은 fold).

2.3 판정 기준 (실행 전에 고정)

레이어 4개를 보므로 유의수준은 Bonferroni 보정 $p < 0.0125$. 각 세트에 독립적으로 적용한다.

기준	조건
1. K 존재	K(지식 질문) ≥ 65% 이고, chance(50%)보다 유의하게 높음 (이항 검정)
2. G 손실	같은 레이어에서 G(지식 질문)의 95% 구간이 50%를 포함
3. 행동 일치	지식 질문 intent의 95% 구간이 50%를 포함하고, 위치 제시 intent ≥ 80%
GO	1과 2를 동시에 만족하는 레이어가 있고 3도 만족
INCONCLUSIVE	위치 제시 intent < 80% (motor floor가 낮아 판정 불가)

3. 데이터셋 (실제 사진)

공식 Act2Answer 에셋은 아직 공개되지 않아(프로젝트 페이지 "Assets (coming soon)") Act2Answer 원본(MLLM-CompBench)과 같은 계열의 공개 사진으로 직접 구성했다. 사진은 **Visual Genome (CC BY 4.0)**, 라벨은 **VAW**(Adobe Research License, 비상업 연구용)에서 가져왔다.

세트	라벨 쌍 (같은 물체의 반대 상태)	라벨당 질문	문제 수	조건당 에피소드
State	open / closed door, clean / dirty toilet, empty / full plate	5	30	60
Attribute	wooden / metal bench, glass / plastic bottle	5	20	40
Emotion	surprised / sleepy person	5	10	20

- **정답 노출 방지:** 라벨 A의 j번째 질문은 사진 (A_j, B_j), 라벨 B의 j번째 질문은 (B_j, A_j)를 쓴다. 각 사진 쌍이 두 사진 각각을 정답으로 한 번씩 등장하므로 사진만 보고는 정답을 알 수 없다 (audit 결과 정답 노출 0건). 질문 문장에는 라벨 단어가 들어가지 않는다.
- **사진 선별:** SigLIP(OpenVLA 비전 인코더 계열)이 (1) 두 상태 중 맞는 쪽을 확률 ≥ 0.8로 고르고 (Emotion은 0.6), (2) 해당 물체를 비슷한 물체(냉장고, 쟁반, 고양이 등)보다 높게 골라야 통과. 이후 육안 검토로 6장을 추가 제외했다. 라벨당 5장을 못 채운 쌍(wet/dry road, leather/fabric chair, happy/sad, angry/calm)은 제외됐다.

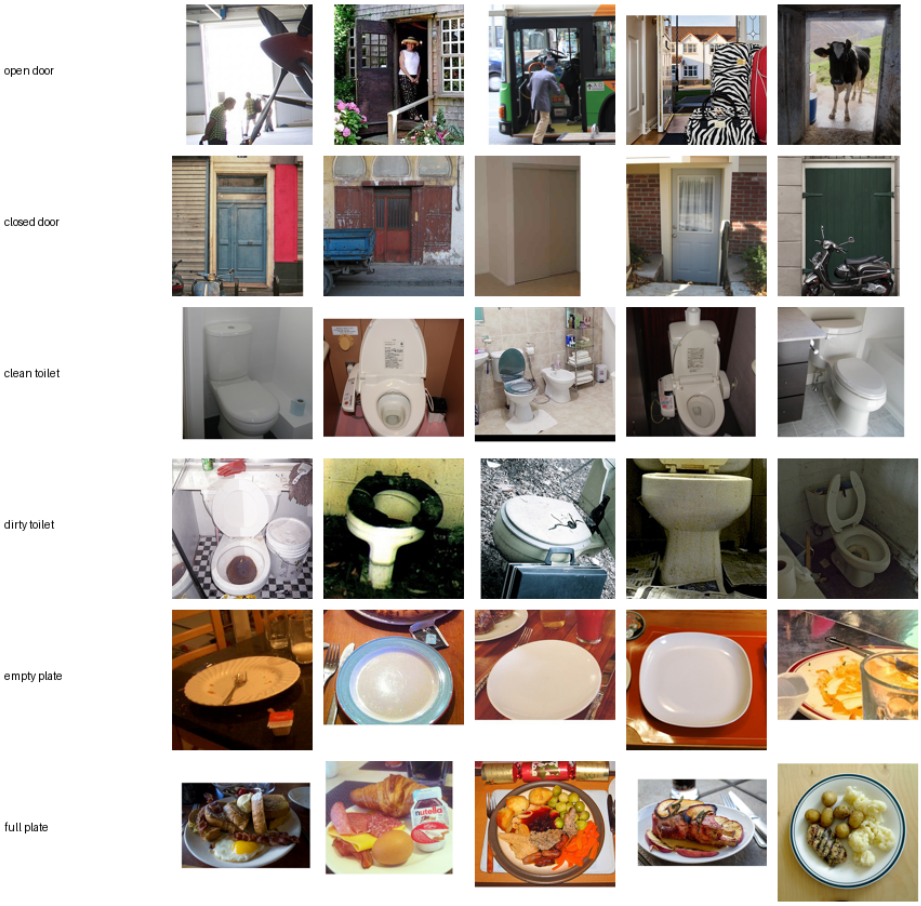


그림 3. State — 라벨별 사진 5장.

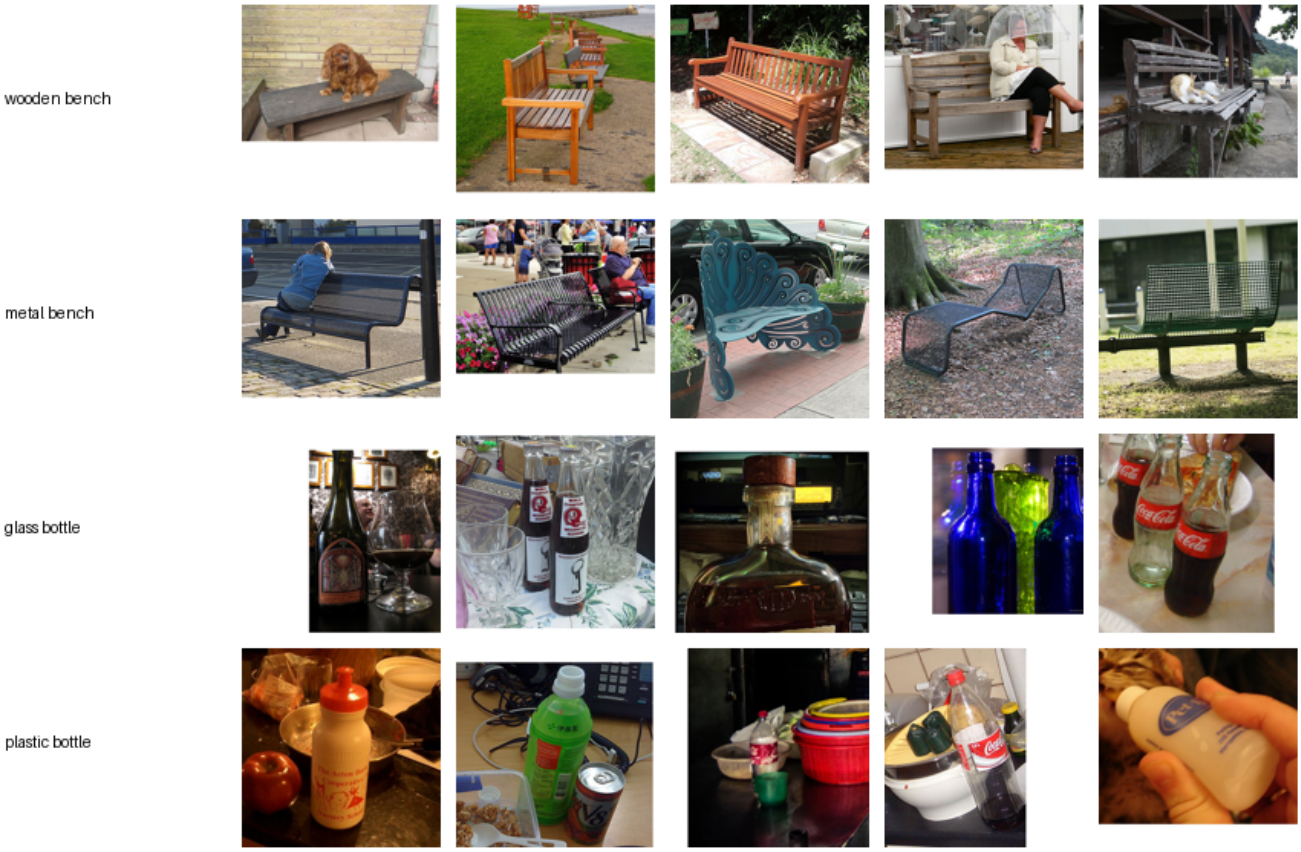


그림 4. Attribute — 라벨별 사진 5장.



그림 5. Emotion — 라벨별 사진 5장.

4. 결과: 본 실험 (실제 사진)

4.1 행동 결과

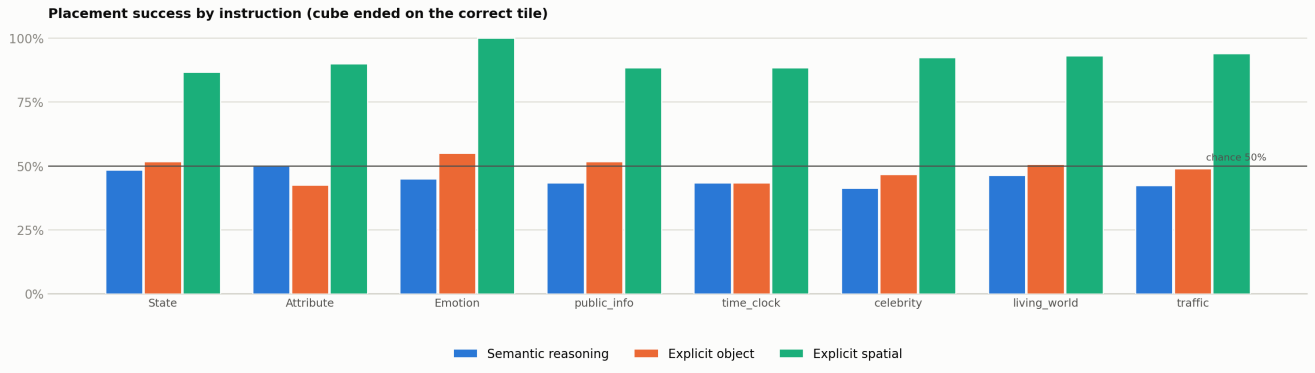


그림 6. 조건별 placement success (본 실험 3개 세트 + 팀원 5개 카테고리). 가로선은 chance(50%).

표 2. Placement success (큐브가 정답 타일 위에 놓인 비율)

테스트	지식 질문	정답 이름 제시	위치 제시
State	48% (29/60)	52% (31/60)	87% (52/60)
Attribute	50% (20/40)	42% (17/40)	90% (36/40)
Emotion	45% (9/20)	55% (11/20)	100% (20/20)
public_info (팀원)	43% (26/60)	52% (31/60)	88% (53/60)
time_clock (팀원)	43% (26/60)	43% (26/60)	88% (53/60)
celebrity (팀원)	41% (124/300)	47% (140/300)	92% (277/300)
living_world (팀원)	46% (139/300)	51% (152/300)	93% (279/300)
traffic (팀원)	42% (127/300)	49% (147/300)	94% (282/300)

세 세트 모두 지식 질문과 정답 이름 제시는 50% 근처, 위치 제시만 높다. 정답 이름을 직접 알려줘도 지식 질문보다 나아지지 않는다 (intent 기준 paired McNemar: State p = 1.0, Attribute p = 0.66, Emotion p = 0.69).

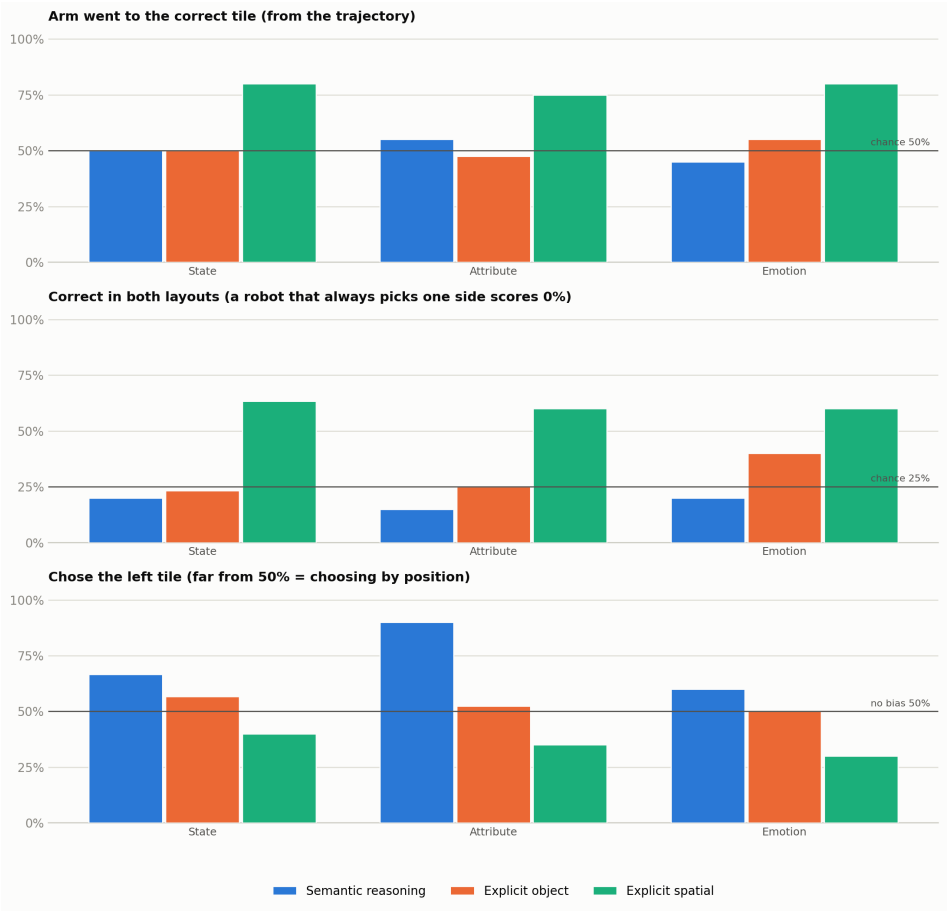


그림 7. (위) 팔이 정답 타일로 갔는가, (가운데) 양쪽 배치 모두 정답, (아래) 왼쪽 선택 비율.

표 3. Intent — 팔이 정답 타일로 갔는가 (궤적 기준)

테스트	지식 질문	정답 이름 제시	위치 제시
State	50% (30/60)	50% (30/60)	80% (48/60)
Attribute	55% (22/40)	48% (19/40)	75% (30/40)
Emotion	45% (9/20)	55% (11/20)	80% (16/20)

표 4. 양쪽 배치 모두 정답 (chance 25%, 한쪽만 고르는 로봇은 0%)

테스트	지식 질문	정답 이름 제시	위치 제시
State	20% (6/30)	23% (7/30)	63% (19/30)
Attribute	15% (3/20)	25% (5/20)	60% (12/20)
Emotion	20% (2/10)	40% (4/10)	60% (6/10)

표 5. 왼쪽 선택 비율 (50%에서 멀수록 위치 편향)

테스트	지식 질문	정답 이름 제시	위치 제시
State	67% (40/60)	57% (34/60)	40% (24/60)
Attribute	90% (36/40)	52% (21/40)	35% (14/40)
Emotion	60% (12/20)	50% (10/20)	30% (6/20)

지식 질문에서는 왼쪽 선택이 60~90%로 치우쳐 있고(Attribute 90%), 양쪽 배치를 모두 맞힌 비율은 chance(25%) 근처이거나 그 아래다 (예외: Emotion의 정답 이름 제시 40%, 10문제). 위치 제시에서만 양쪽 배치를 모두 맞히는 비율이 높다 (60~63%).

4.2 내부 표현 (probe) 결과

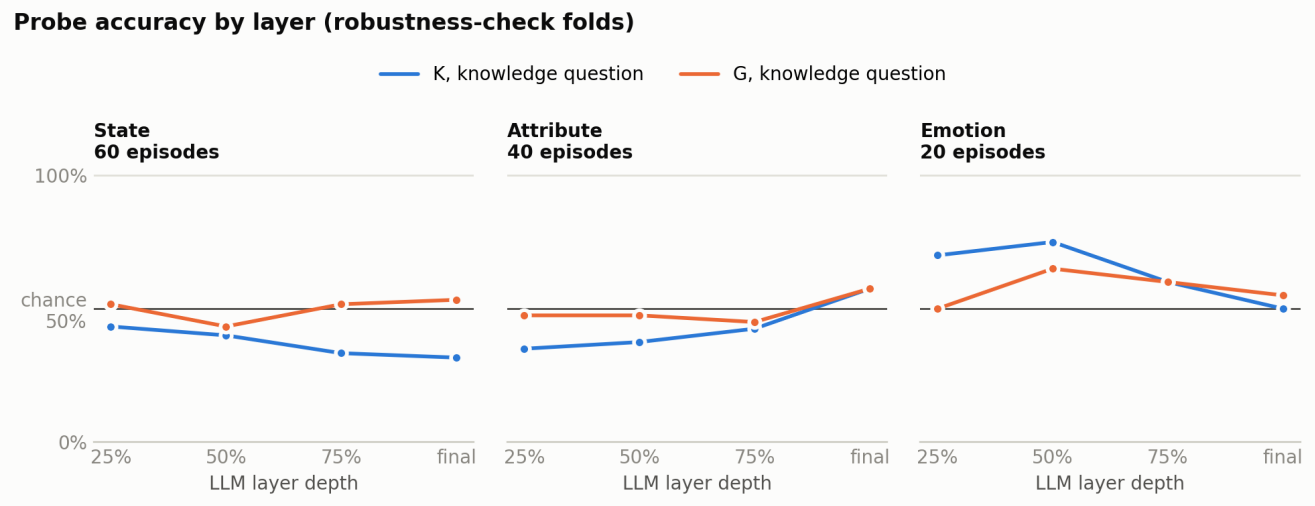


그림 8. 레이어별 probe 정확도 (robustness check fold). 파랑 = K (지식 질문), 주황 = G (지식 질문). 가로선 = chance(50%).

표 6. Probe 정확도 — robustness check fold (같은 사진 쌍의 질문을 같은 fold에 묶음)

테스트	레이어	K (지식 질문)	K vs chance p값	G (지식 질문)
State	25%	43% (26/60)	0.3663	52%
State	50%	40% (24/60)	0.1550	43%
State	75%	33% (20/60)	0.0135	52%
State	final	32% (19/60)	0.0062	53%
Attribute	25%	35% (14/40)	0.0807	48%
Attribute	50%	38% (15/40)	0.1539	48%
Attribute	75%	42% (17/40)	0.4296	45%

테스트	레이어	K (지식 질문)	K vs chance p값	G (지식 질문)
Attribute	final	57% (23/40)	0.4296	57%
Emotion	25%	70% (14/20)	0.1153	50%
Emotion	50%	75% (15/20)	0.0414	65%
Emotion	75%	60% (12/20)	0.5034	60%
Emotion	final	50% (10/20)	1.0000	55%

State·Attribute에서 K는 모든 레이어에서 chance(50%) 이하이거나 근처다(최대 57%, Attribute 최종 레이어) → K가 표현에 나타나지 않음. 일부 레이어에서 chance보다 유의하게 낮은 값(예: State 최종 레이어 32%)은 정보가 아니라 cross-validation 분할의 artifact다: 같은 사진 쌍이 반대 정답으로 학습 fold에 들어 있어, 장면을 외운 probe가 반대로 답하게 된다. Emotion은 K가 70~75%까지 오르지만 chance와의 차이가 유의하지 않다 (최고 15/20, p = 0.041 > 0.0125; 조건당 20 에피소드로 검정력 부족). G는 세 세트 모두 chance 근처.

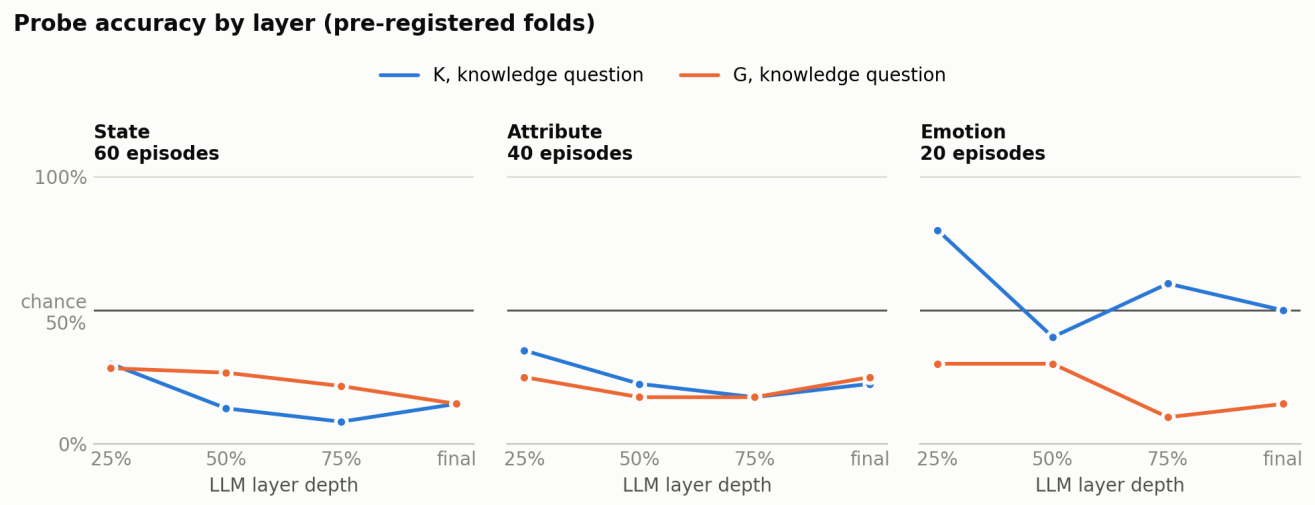


그림 9. 사전 등록 fold 결과. 이 fold 방식에서는 테스트 질문과 같은 사진 쌍이 반대 정답으로 학습에 들어가 장면 정보가 probe를 chance 아래로 밀어낸다 (State·Attribute의 낮은 값). Emotion은 25% 레이어에서 80% (16/20, p = 0.0118)로 기준을 겨우 넘어 사전 등록 판정이 GO이지만, 이 artifact를 제거한 robustness check에서는 유지되지 않는다.

표 7. Probe 정확도 — 사전 등록 fold

테스트	레이어	K (지식 질문)	K vs chance p값	G (지식 질문)
State	25%	30% (18/60)	0.0027	28%
State	50%	13% (8/60)	<0.0001	27%
State	75%	8% (5/60)	<0.0001	22%
State	final	15% (9/60)	<0.0001	15%
Attribute	25%	35% (14/40)	0.0807	25%
Attribute	50%	22% (9/40)	0.0007	18%
Attribute	75%	18% (7/40)	<0.0001	18%
Attribute	final	22% (9/40)	0.0007	25%
Emotion	25%	80% (16/20)	0.0118	30%
Emotion	50%	40% (8/20)	0.5034	30%
Emotion	75%	60% (12/20)	0.5034	10%
Emotion	final	50% (10/20)	1.0000	15%

5. 결과: 팀원 실험 (public_info, time_clock, celebrity, living_world, traffic)

팀원이 공유한 결과(컴종설 실험1, 2개 파일)를 문제 단위로 옮겨 다시 집계했다. 옮긴 값으로 계산한 요약이 팀원 요약표의 **24칸(카테고리 5 × 과제 3, swap/no swap)과 모두 일치**함을 확인했다. 각 에피소드는 3회 반복. public_info·time_clock은 10문제, celebrity·living_world·traffic은 50문제(문제 2k와 2k+1은 같은 두 타일, 정답이 서로 반대). 지식 질문 예: "Place the cube on the sign associated with a more urgent situation." (public_info), "Place the cube on the singer who released the album 21." (celebrity, Adele vs Angelina Jolie), "Place the cube on the species that is the largest living land animal." (living_world), "Place the cube on the sign that warns that trains may cross the road ahead." (traffic).

표 8. 팀원 요약 (팀원 표와 같은 형식)

카테고리	문제 수	과제	swap	no swap	전체
public_info	10	정답 이름 제시 (Explicit object)	63.3% (19/30)	40.0% (12/30)	51.7% (31/60)
public_info	10	위치 제시 (Explicit spatial)	83.3% (25/30)	93.3% (28/30)	88.3% (53/60)
public_info	10	지식 질문 (Semantic reasoning)	43.3% (13/30)	43.3% (13/30)	43.3% (26/60)
time_clock	10	정답 이름 제시 (Explicit object)	46.7% (14/30)	40.0% (12/30)	43.3% (26/60)
time_clock	10	위치 제시 (Explicit spatial)	86.7% (26/30)	90.0% (27/30)	88.3% (53/60)
time_clock	10	지식 질문 (Semantic reasoning)	33.3% (10/30)	53.3% (16/30)	43.3% (26/60)
celebrity	50	정답 이름 제시 (Explicit object)	40.7% (61/150)	52.7% (79/150)	46.7% (140/300)
celebrity	50	위치 제시 (Explicit spatial)	91.3% (137/150)	93.3% (140/150)	92.3% (277/300)
celebrity	50	지식 질문 (Semantic reasoning)	45.3% (68/150)	37.3% (56/150)	41.3% (124/300)
living_world	50	정답 이름 제시 (Explicit object)	52.7% (79/150)	48.7% (73/150)	50.7% (152/300)
living_world	50	위치 제시 (Explicit spatial)	92.0% (138/150)	94.0% (141/150)	93.0% (279/300)
living_world	50	지식 질문 (Semantic reasoning)	54.7% (82/150)	38.0% (57/150)	46.3% (139/300)
traffic	50	정답 이름 제시 (Explicit object)	53.3% (80/150)	44.7% (67/150)	49.0% (147/300)
traffic	50	위치 제시 (Explicit spatial)	94.7% (142/150)	93.3% (140/150)	94.0% (282/300)
traffic	50	지식 질문 (Semantic reasoning)	42.7% (64/150)	42.0% (63/150)	42.3% (127/300)

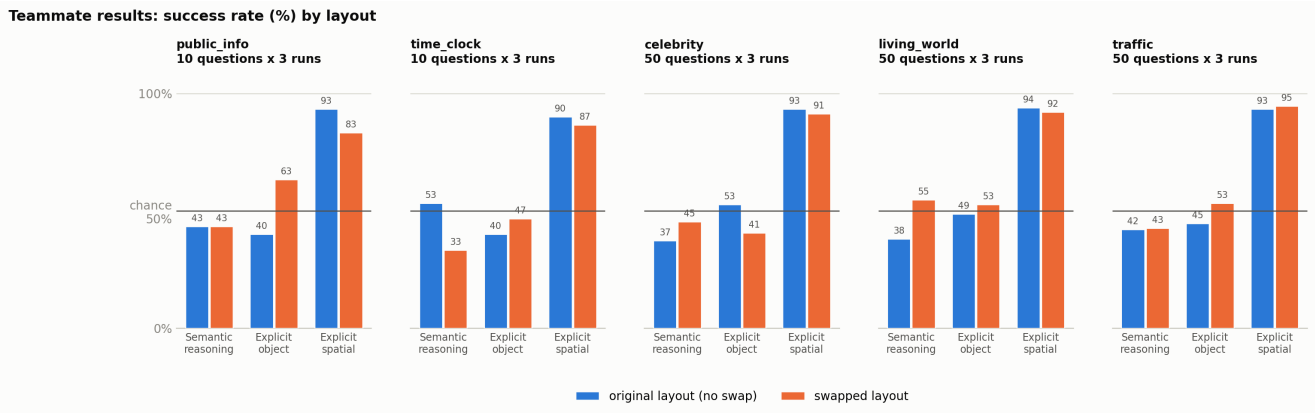


그림 10. 팀원 결과: 원래 배치(no swap)와 바꾼 배치(swap)의 성공률.

표 9. 정답 위치별 성공률 (팀원) — 정답이 왼쪽/오른쪽에 있을 때

카테고리	과제	정답이 왼쪽일 때	정답이 오른쪽일 때	차이 (왼 − 오)
public_info	지식 질문	13.3% (4/30)	73.3% (22/30)	-60%p
public_info	정답 이름 제시	40.0% (12/30)	63.3% (19/30)	-23%p
public_info	위치 제시	100.0% (30/30)	76.7% (23/30)	+23%p
time_clock	지식 질문	73.3% (22/30)	13.3% (4/30)	+60%p
time_clock	정답 이름 제시	56.7% (17/30)	30.0% (9/30)	+27%p
time_clock	위치 제시	93.3% (28/30)	83.3% (25/30)	+10%p
celebrity	지식 질문	22.0% (33/150)	60.7% (91/150)	-39%p

카테고리	과제	정답이 왼쪽일 때	정답이 오른쪽일 때	차이 (왼 − 오)
celebrity	정답 이름 제시	74.0% (111/150)	19.3% (29/150)	+55%p
celebrity	위치 제시	96.0% (144/150)	88.7% (133/150)	+7%p
living_world	지식 질문	35.3% (53/150)	57.3% (86/150)	-22%p
living_world	정답 이름 제시	54.0% (81/150)	47.3% (71/150)	+7%p
living_world	위치 제시	94.0% (141/150)	92.0% (138/150)	+2%p
traffic	지식 질문	46.0% (69/150)	38.7% (58/150)	+7%p
traffic	정답 이름 제시	58.0% (87/150)	40.0% (60/150)	+18%p
traffic	위치 제시	96.7% (145/150)	91.3% (137/150)	+5%p

표 9가 핵심이다. 지식 질문·정답 이름 제시에서 성공률이 정답 위치에 따라 크게 갈린다: public_info 지식 질문 13% ↔ 73% (정답이 오른쪽일 때 높음), time_clock은 반대로 73% ↔ 13%, celebrity는 지식 질문 22% ↔ 61%, 정답 이름 제시 74% ↔ 19%. 즉 로봇은 질문 내용보다 **세트·지시마다 정해진 한쪽**을 주로 고르며, 그 쪽에 정답이 있을 때 "성공"한다. living_world·traffic은 편향이 더 작지만(차이 2~22%p) 전체 성공률은 여전히 chance 수준이다. 위치 제시에서만 양쪽 모두 높다 (77~100%). 본 실험의 왼쪽 선택 편향(표 5)과 같은 현상이다.

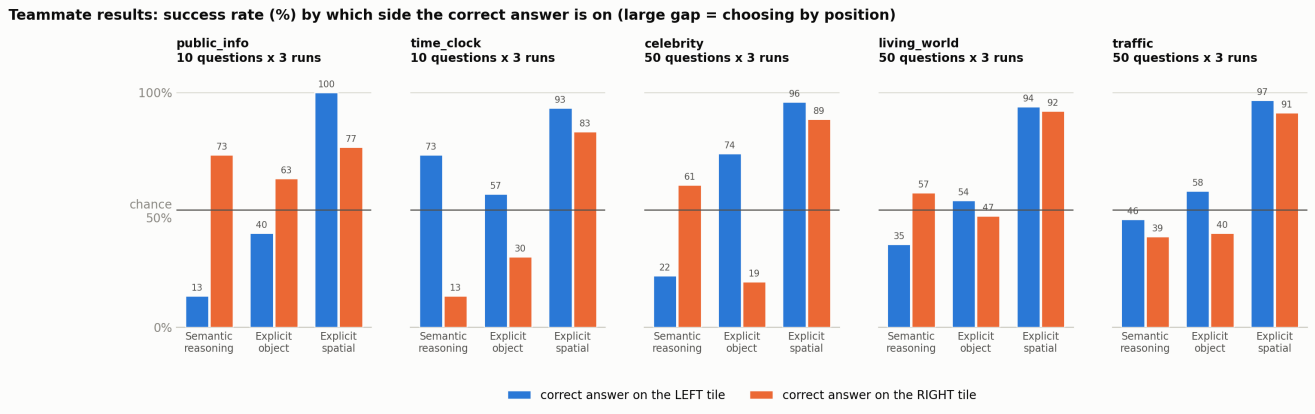


그림 11. 팀원 결과: 정답이 왼쪽/오른쪽에 있을 때의 성공률.

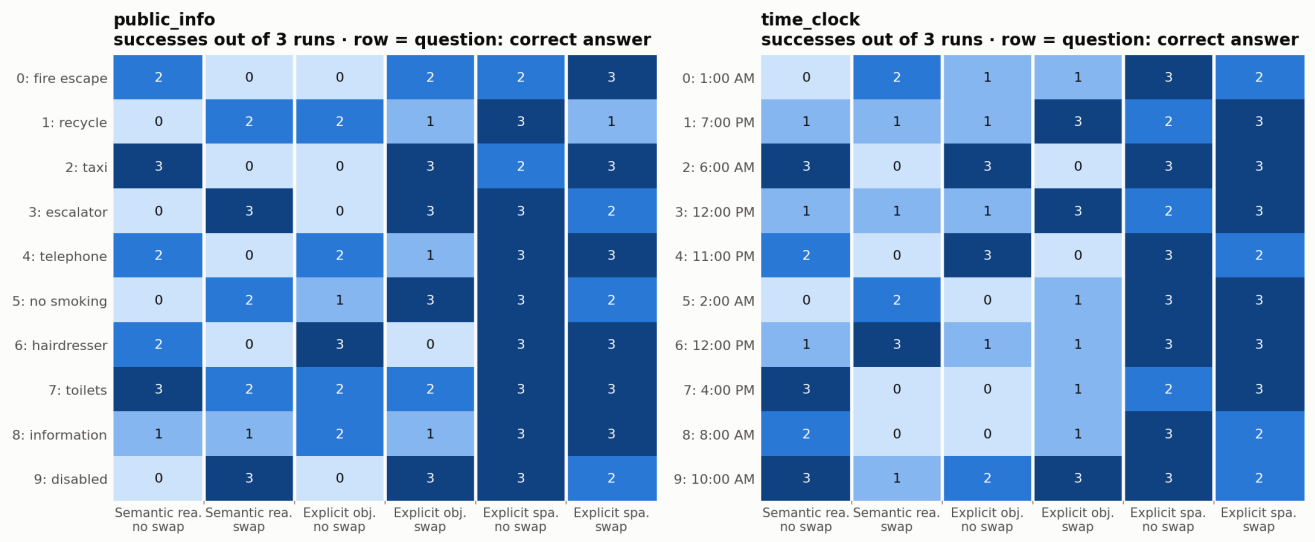


그림 12. 팀원 결과 (10문제 세트): 문제별 성공 횟수 (3회 중). 행 = 문제 번호: 정답.

표 10. 팀원 문제별 결과 — public_info (50문제 세트의 문제별 결과는 `diagnostics/report/teammate_results.json`) (각 칸: no swap · swap, 3회 중 성공 횟수)

#	지식 질문 (… associated with / showing a time when …)	타일 (no swap: 왼쪽 / 오른쪽)	정답	지식 질문	정답 이름	위치
0	a more urgent situation	hairdresser / fire escape	fire escape	2 · 0	0 · 2	2 · 3

#	지식 질문 (… associated with / showing a time when …)	타일 (no swap: 왼쪽 / 오른쪽)	정답	지식 질문	정답 이름	위치
1	environmental protection	recycle / no entry	recycle	0 · 2	2 · 1	3 · 1
2	a service you are more likely to pay for	stairs / taxi	taxi	3 · 0	0 · 3	2 · 3
3	something that uses electricity	escalator / stairs	escalator	0 · 3	0 · 3	3 · 2
4	talking to someone	recycle / telephone	telephone	2 · 0	2 · 1	3 · 3
5	protecting people's health	no smoking / no entry	no smoking	0 · 2	1 · 3	3 · 2
6	changing someone's appearance	stairs / hairdresser	hairdresser	2 · 0	3 · 0	3 · 3
7	a bodily need	toilets / no parking	toilets	3 · 2	2 · 2	3 · 3
8	finding information while sightseeing	no dogs / information	information	1 · 1	2 · 1	3 · 3
9	a person using a wheelchair	disabled / fire escape	disabled	0 · 3	0 · 3	3 · 2

표 11. 팀원 문제별 결과 — time_clock

#	지식 질문 (… associated with / showing a time when …)	타일 (no swap: 왼쪽 / 오른쪽)	정답	지식 질문	정답 이름	위치
0	stars are more likely to be visible	10:00 AM / 1:00 AM	1:00 AM	0 · 2	1 · 1	3 · 2
1	closer to sunset	6:00 AM / 7:00 PM	7:00 PM	1 · 1	1 · 3	2 · 3
2	closer to sunrise	6:00 AM / 7:00 PM	6:00 AM	3 · 0	3 · 0	3 · 3
3	outdoor shadows are shorter	9:00 AM / 12:00 PM	12:00 PM	1 · 1	1 · 3	2 · 3
4	streetlights are more likely to be on	11:00 PM / 2:00 PM	11:00 PM	2 · 0	3 · 0	3 · 2
5	you are more likely to need a flashlight outdoors	1:00 PM / 2:00 AM	2:00 AM	0 · 2	0 · 1	3 · 3
6	closer to when the sun is highest	11:00 PM / 12:00 PM	12:00 PM	1 · 3	1 · 1	3 · 3
7	it is typically warmer outdoors	4:00 PM / 5:00 AM	4:00 PM	3 · 0	0 · 1	2 · 3
8	a typical morning commute time	8:00 AM / 6:00 PM	8:00 AM	2 · 0	0 · 1	3 · 2
9	school classes are typically in session	10:00 AM / 7:00 PM	10:00 AM	3 · 1	2 · 3	3 · 2

5.1 본 실험과 팀원 실험 비교

테스트	지식 질문	정답 이름 제시	위치 제시
State (사진, 본 실험)	48%	52%	87%
Attribute (사진, 본 실험)	50%	42%	90%
Emotion (사진, 본 실험)	45%	55%	100%
public_info (팀원, 10문제 × 3회)	43%	52%	88%
time_clock (팀원, 10문제 × 3회)	43%	43%	88%
celebrity (팀원, 50문제 × 3회)	41%	47%	92%
living_world (팀원, 50문제 × 3회)	46%	51%	93%
traffic (팀원, 50문제 × 3회)	42%	49%	94%

에셋, 질문, 실행자가 달라도 8개 세트 모두에서 같은 패턴이 재현된다 (지식 질문 41~50%, 정답 이름 제시 42~55%, 위치 제시 87~100%).

6. 해석

1. **Motor 문제가 아니다.** 위치 제시 지시는 모든 세트에서 87~100% 성공한다.
2. **정답 이름을 알려줘도 해결되지 않는다.** Explicit object ≈ Semantic reasoning ≈ chance. 로봇은 지시 내용보다 위치(한쪽 타일)로 고르며, 이 편향은 본 실험과 팀원 실험 모두에서 나타난다. 실패는 "지식을 몰라서"보다 앞서, 단어/사진을 화면 속 위치로 연결하는 grounding 단계에서 일어난다.
3. **가설의 전제(K가 표현에 있음)가 실사에서 확인되지 않았다.** State·Attribute에서는 정답이 hidden state에서 선형으로 읽히지 않는다. 따라서 "K → G에서 손실"인지, 그 전에 사진 내용과 질문을 연결하지 못하는 것인지(F1)를 probe로는 구분할 수 없다.
4. Probe 결과는 "선형 분류기로 decode 가능"이라는 뜻이며, 모델이 그 정보를 행동에 사용하는지는 보여주지 않는다 (causal tracing 단계의 과제).

7. 한계 및 실행 중 수정한 문제

구분	내용
에셋	공식 Act2Answer 에셋이 아닌 공개 사진(Visual Genome)으로 구성한 세트. 장면 사진을 잘라낸 것이라 배경이 섞임
규모	본 실험은 seed 1개, 에피소드 1회 실행 (팀원은 3회). Emotion은 라벨 쌍 1개, 조건당 20 에피소드로 검정력 부족
질문	본 실험 질문은 Claude가 작성한 초안, 팀 검토 전 (`diagnostics/dataset_build/photo_output/*_questions.csv`)
팀원 데이터	공유받은 PDF 2개에서 옮겨 적은 값 (요약표 24칸과 일치 확인). 팀원 실험은 probe(hidden state)가 없어 행동 결과만 비교 가능
수정 1	첫 사진 빌드에서 "sad person"에 개·고양이, "open door"에 냉장고가 섞임 → 물체 확인 단계 추가 + 육안 검토 6장 제외 후 재실행
수정 2	K probe가 두 타일에 같은 점수를 줄 때 둘 다 오답 처리하던 버그 → 동점은 chance로 처리
수정 3	사전 등록 fold에서 장면 정보가 probe를 chance 아래로 밀어내는 분할 artifact 발견 → robustness check (같은 사진 쌍끼리 같은 fold) 추가
판정 기준	판정 기준 1의 비교 대상을 chance(50%, 이항 검정)로 제시함. 실행 전 기준과 판정 결과는 동일

8. 다음 단계 제안

1. **위치 편향 정량화:** 팀원 세트와 본 세트 모두에서 정답 위치별 성공률을 기본 지표로 보고 (표 9 형식). celebrity처럼 지시 종류에 따라 편향 방향이 바뀌는 이유도 확인.
2. **텍스트 전용 대조 실험:** 이미지 없이 질문만으로 K가 decode되는지 확인 → K가 언어 단계에서부터 없는지 구분.
3. **Emotion 재실행:** 얼굴 데이터셋(예: CEED)으로 라벨 쌍과 문제 수를 늘려 검정력 확보.
4. **질문 검토와 반복 확대:** 팀 검토 후 seed 2~3개(팀원처럼 3회 반복)로 재실행.
5. 공식 Act2Answer 에셋이 공개되면 동일 파이프라인으로 재현. K→G 병목이 확인되는 세트에 한해 activation patching (causal tracing).

9. 재현 방법 및 파일 위치

```
# 사진 세트 생성 + 평가 + 분석을 한 번에 (Slurm, 자동 연결)
sbatch slurm/photo_build.sbatch
# 표 / 그림 / 보고서
python -m diagnostics.export_results_table          # outputs/results_raw.xlsx (팀원 형식)
python -m diagnostics.plot_results --assets photo_state_v1 photo_attribute_v1
  photo_emotion_v1 --out-dir diagnostics/report/figures
python diagnostics/report/plot_teammate.py          # 팀원 결과 그림
```

```
python diagnostics/report/build_pdf.py --fonts ~/YeahPick/data/fonts
```

내용	위치
설계·판정 기준·결과 기록	diagnostics/HYPOTHESIS_PILOT.md
전체 분석 표	outputs/photo_hypothesis/<세트>/<fold>/report.md
에피소드별 결과 (엑셀)	outputs/results_raw.xlsx
팀원 결과 (옮겨 적은 원본)	diagnostics/report/teammate_results.json
실행 영상	outputs/openvla-photo_<세트>-<조건>-<배치>-q…-seed0/glob/vis_0_test/*.mp4
사진 출처·라이선스	diagnostics/dataset_build/photo_output/<세트>_credits.csv